

PROYECTO FINAL · ALMACENAMIENTO DE DATOS · 2026

Lo que no se vende hoy, *se bota.*

Laura Victoria Gallo Payana · Erika Alejandra Echeverry · Juan David Acosta Castro



uao

Contexto y problemática



CONTEXTO



PROBLEMÁTICA



Por qué una franquicia bota comida



SE DECIDE ANTES

Preparado

Por franja, antes de abrir. Por frescura, nada pasa al día siguiente.

–

LLEGA DESPUÉS

Demanda

Cambia con el clima, la movilidad urbana y la quincena.

=

EL DESAJUSTE

Diferencia

Su valor absoluto, sumado, es la Tasa de Desviación de Demanda.

SEGÚN EL SIGNO DE LA DIFERENCIA

> 0

Merma

Insumo pagado que termina en la basura. Lo mide el CMV.

= 0

Punto ideal

Se preparó exactamente lo que se vendió. Es la meta.

< 0

Venta perdida

Cliente sin producto: un ingreso que no entra.

Para quién trabajan los datos

Gerente de Operaciones y Abastecimiento

Controla los costos de inventario, minimiza el desperdicio y protege el margen frente a la volatilidad de precios de los insumos.

SUS TRES KPIS

Costo de Merma sobre Venta (CMV)

$$\Sigma \text{costo_merma} / \Sigma \text{venta} \times 100$$

Cuánto del dinero vendido se pierde en insumos botados.

Tasa de Desviación de Demanda

$$\Sigma |\text{preparado} - \text{demanda}| / \Sigma \text{demanda} \times 100$$

Qué tanto se aleja lo preparado de lo vendido.

Costo por Categoría de Insumo

$$\text{costo_merma_categoría} / \text{costo_merma_total} \times 100$$

Dónde se concentra el desperdicio.

Stack tecnológico del pipeline

EXTRACCIÓN

kagglehub

Descarga por API con respaldo

PROCESAMIENTO

pandas + numpy

Limpieza, tipos y agregaciones

EDA

Jupyter + Matplotlib

Diagnóstico y gráficas

CONFIGURACIÓN

YAML + .env

Parámetros y credenciales

CONEXIÓN

SQLAlchemy + psycopg2

Carga transaccional

BASE DE DATOS

PostgreSQL 16

Esquemas silver y gold

CONTENEDORES

Docker Compose

Base y dashboard reproducibles

VISUALIZACIÓN


Grafana 12

Provisioning automático

TRAZABILIDAD

logging

Cada paso queda en logs.txt






Arquitectura medallón en acción

```
extract_excel.py
→ data/bronze
```

```
clean_excel.py
→ data/silver
```

```
gold_data.py
→ data/gold
```

```
load_database.py
→ silver. gold.
```



Extracción: dos fuentes por API

FUENTE 1 • VENTAS

Fast Food Sales Report

1000 transacciones • 10 columnas

Ítem, precio, cantidad, monto, tipo de pago y franja horaria

FUENTE 2 • BENCHMARK

Food Waste Index (UNEP)

214 países • 12 columnas

Desperdicio por hogar, comercio y servicio de alimentos

extract_excel.py

```
# Normalización de columnas al español
```

```
"order_id" → "id_orden"
```

```
"date" → "fecha"
```

```
"item_name" → "nombre_item"
```


```
"quantity" → "cantidad"
```

```
"transaction_amount" → "monto_transaccion"
```

```
"transaction_type" → "tipo_pago"
```

```
"time_of_sale" → "franja_horaria"
```

data/bronze/*.csv



Diagnóstico de calidad de los datos

Problema	Qué encontró el EDA	Decisión en plata
Fechas en tres formatos	438 «8/23/2022» · 159 «11/20/2022» · 403 «07-03-2022»	Detectar el formato y convertir
Valores nulos	tipo_pago: 107 filas (10,7 %)	Etiquetar como «Desconocido»
Duplicados	0 exactos y 0 por id_orden	Validar con clave primaria
Montos atípicos	Hasta 900, que es 60×15	Se conservan: son pedidos reales
Coherencia de montos	Monto = precio $\times$ cantidad en las 1000 filas	Recalcular si alguna no cuadra
Columna sin uso	genero_cajero no aporta al problema	Eliminar en plata



Diagnostico :El misterio de las 403 fechas

39,5 %

de los días de un mes van del 1 al 12



clean_excel.py · simplificado

```
def _formato_fechas_guion(texto, referencia):
    partes = texto.str.extract("(dd)-(dd)-(dddd)")
    primero = (partes[0] > 12).sum() # → 0
    segundo = (partes[1] > 12).sum() # → 0
    if segundo and not primero:
        return "%m-%d-%Y"
    if primero and not segundo:
        return "%d-%m-%Y"
    # Empate: el formato con más fechas en rango
    # {%m-%d-%Y: 376, %d-%m-%Y: 231}
    return max(dentro, key=dentro.get)
```


40,3 %

de las fechas venían con guion, y
ninguna tenía un número mayor que 12

Limpieza y modelado: plata y oro

`clean_excel.py` • capa plata

- Fechas de 3 formatos convertidas: 0 sin convertir
- 107 nulos etiquetados y 0 duplicados
- Montos validados contra $\text{precio} \times \text{cantidad}$
- +5 columnas de calendario, incluida `es_quincena`



`gold_data.py` • capa oro

- Calendario completo: $364 \text{ días} \times 7 \text{ ítems} = 2548 \text{ filas}$
- Días sin ventas en cero: 67,7 % de las filas
- Variabilidad, franjas, meses y benchmark
- Merma simulada y los 3 KPIs en 9 tablas

Modelo de datos de la capa

PLATA

silver.ventas

PK (id_orden)

fecha · nombre_item · cantidad ·

monto_transaccion · franja_horaria

silver.benchmark

PK (pais)

servicio_alimentos_kg ·

nivel_confianza

ORO · HECHOS

gold.hechos_demanda_diaria

PK (fecha, nombre_item)

unidades · monto · es_quincena ·

2548 filas

gold.merma_simulada_diaria

PK (fecha, nombre_item)

preparado · vendido ·

merma_unidades · costo_merma

ORO · AGREGADOS

demanda_dia_franja

variabilidad_item

ventas_mensuales


efecto_calendario

kpis_simulados_resumen


kpis_simulados_mensual

benchmark_contexto


El EDA en el notebook




monto: histograma + boxplot



ítems: unidades vs monto



unidades: franja × día



benchmark: Colombia en el mundo

HALLAZGOS

La demanda no es pareja

Cambia según el día, la hora y el producto.
Cada cambio que no se anticipa termina en merma.



Hallazgos :Día y hora juntos mueven la demanda

Lun	Mar	Mié	Jue	Vie	Sáb	Dom	Mañana
225	149	214	253	238	178	317	Tarde
280	223	313	287	161	234	216	Tarde-noche
135	209	276	231	249	198	242	Noche
286	214	278	196	208	313	264	Medianoche
237	253	204	176	207	251	247	


+14 %
 Entre franjas horarias (1540 vs 1759 unidades)

+23 %
 Entre días de la semana (1048 vs 1286 unidades)

+135 %
 Entre combinaciones de día y franja (135 vs 317)

Volumen no es lo mismo que valor

PARTICIPACIÓN EN EL MONTO VENDIDO



Bebidas: volumen

Cold coffee y Sugarcane juice son los más vendidos en unidades.

Sandwich y Frankie: valor

Con menos unidades, suman el 44,8 % del dinero.

Se vende solo uno de cada tres días

30–35 %

de los días tiene al menos una venta
de cada producto

Los otros dos tercios, su demanda es cero.

CV = DESVIACIÓN / MEDIA DE LA DEMANDA DIARIA

Sandwich



Aalopuri



Vadapav



Frankie



Panipuri



Cold coffee



Sugarcane juice



Con un CV cercano a 2, la desviación duplica el promedio. El Sandwich es el más irregular.

Producir con promedios genera merma

```
simular_merma() · gold_data.py

# Para cada ítem y cada día
pronostico = promedio(mismo día, 4 semanas)
preparado = ceil(pronostico × 1.10)
vendido = min(demanda, preparado)
merma = preparado - vendido
costo = merma × precio × 0.35
```

Valores inflados por el dataset: tiene unas 2,7 órdenes al día; una franquicia real atiende cientos. Se valida el método y la comparación entre productos.

95,3 %

Costo de Merma sobre
Venta (CMV)


154,8 %

Tasa de Desviación de
Demanda

72,5 %

de lo preparado
termina en merma

Dónde se concentra la merma




Ítem	Costo de merma	CMV	Desviación
Sandwich	26,5 %	119,7 %	173,9 %
Frankie	20,4 %	91,4 %	152,9 %
Cold coffee	18,8 %	88,7 %	151,8 %
Sugarcane juice	10,6 %	76,1 %	143,1 %
Panipuri	8,3 %	85,3 %	148,6 %
Aalopuri	7,8 %	95,2 %	157,9 %
Vadapav	7,7 %	102,1 %	160,6 %

El benchmark: contexto, no meta


Hogar



Comercio




Servicio de alimentos



≈ 130

países caen en el mismo rango que Colombia en servicio de alimentos: es un valor extrapolado, no medido.



PostgreSQL con un esquema por capa

silver

ventas 1000

benchmark 214

gold

hechos_demanda_diaria 2548

merma_simulada_diaria 2499

demanda_dia_franja 35

ventas_mensuales 12

kpis_simulados_mensual 12

kpis_simulados_resumen 10

variabilidad_item 7

benchmark_contexto 4

efecto_calendario 4

load_database.py

```
CREATE SCHEMA IF NOT EXISTS gold;
-- df.to_sql() por cada CSV de data/gold
ALTER TABLE gold.hechos_demanda_diaria
    ADD PRIMARY KEY (fecha, nombre_item);
SELECT COUNT(*) FROM gold.hechos_demanda_diaria;
-- 2548 en la base = 2548 cargadas: OK
```

PK en 11 tablas


fecha_carga

verificación de filas

PostgreSQL 16 · Docker

PostgreSQL

Visualizacion :Grafana



KPIs en tarjetas: CMV, desviación y merma



Filtro por ítem y por rango de fechas



Demanda diaria con media móvil y mapa de calor



14 consultas SQL directas a la capa oro

Conclusiones

El proyecto permitió desarrollar un pipeline ETL completo y reproducible para analizar las mermas en franquicias de comida rápida. Los resultados evidencian que la variabilidad de la demanda por día, franja horaria y producto puede generar sobreproducción y desperdicio. Aunque los valores actuales son simulados, la metodología y la arquitectura ya están preparadas para conectarse a datos reales y apoyar decisiones de producción, inventario y abastecimiento.



“Con datos bien organizados, es posible anticipar la demanda y reducir las mermas.”

Conclusiones

01

Planear por día y franja

Ajustar la producción a cada combinación, no a un promedio diario.

02

Vigilar primero el Sandwich

Es el ítem más irregular y el de mayor costo de merma.

03

Registrar producción y merma

Sin lo preparado y lo botado por día, el CMV real no se mide.

04

Sumar clima y quincena

Llevar al pronóstico las variables del problema que faltan.